

کاتالوگ جامع زیرساخت‌های پردازشی و هوش مصنوعی آذرخش (نسخه ۲۰۲۶)

مقدمه و راهنمای انتخاب محصول

این سند شامل لیست دقیق تجهیزات، مشخصات فنی، کدهای شناسایی (SKU) و تعرفه‌های مالی شرکت آذرخش است. تمامی قیمت‌ها به تومان بوده و برای مدت ۳۰ روز از تاریخ صدور معتبر می‌باشد. محصولات این کاتالوگ برای اجرای مدل‌های زبانی بزرگ (LLM) در محیط‌های ایزوله و Local-First بهینه‌سازی شده‌اند.

۱. رده سرورهای محاسباتی سنگین (Enterprise AI Servers)

این سرورها قلب تپنده دیتاسنترهای هوش مصنوعی هستند.

۱.۱. مدل آذرخش Titan-X9 (پرچمدان)

سنگین‌ترین مدل طراحی شده برای Training و Fine-tuning مدل‌های بالای ۷۰ میلیارد پارامتر.

• کد کالا (SKU): AZ-SRV-T9-2026

• مشخصات فنی پایه:

• CPU: 2x AMD EPYC 9754 (Bergamo) - 256 Cores / 512 Threads

• RAM: 2TB DDR5-4800MHz ECC2 (قابلیت ارتقا تا 6TB)

• GPU Support: پشتیبانی از ۸ عدد NVIDIA H100 80GB SXM5

• Networking: 4x 400GbE NDR InfiniBand

• Storage: 4x 15.36TB NVMe Gen5 Enterprise SSD

• جدول قیمت‌گذاری بر اساس پیکربندی GPU:

وضعیت موجودی قیمت واحد (تومان) حافظه گرافیکی کل تعداد GPU

موجود ۱,۸۵۰,۰۰۰,۰۰۰ ۰ گیگابایت بدون GPU

سفارشی (۱۵ روز) ۶,۴۰۰,۰۰۰,۰۰۰ ۱۶۰ گیگابایت ۲ عدد H100

وضعیت موجودی قیمت واحد (تومان) حافظه گرافیکی کل تعداد GPU

سفارشی (۳۰ روز) ۱۱,۲۰۰,۰۰۰,۰۰۰ ۳۲۰ گیگابایت ۴ عدد H100

استعلامی ۲۰,۹۰۰,۰۰۰,۰۰۰ ۶۴۰ گیگابایت ۸ عدد H100

۱.۲. مدل آذرخش Helios-G4 (بهینه شده برای استنتاج/Inference)

مناسب برای اجرای Agentic RAG و سرویس دهی همزمان به بیش از ۵۰۰ کلاینت داخلی.

- کد کالا (SKU): AZ-SRV-HG4-INF
- مشخصات فنی:
- CPU: Intel Xeon Platinum 8480+ (56 Cores)
- RAM: 512GB DDR5 Registered
- Storage: 7.68TB NVMe Read-Intensive2 x
- قیمت: ۱,۱۵۰,۰۰۰,۰۰۰ تومان
- توضیحات فنی: این دستگاه دارای بهینه سازی خاص در سطح BIOS برای کاهش Latency در زمان Token Streaming است.

۲. ایستگاه های کاری پردازش محلی (AI Workstations)

برای تیم های توسعه و محیط های تحقیق و توسعه (D&R) که نیاز به توان پردازشی بالا روی دسکتاپ دارند.

۲.۱. ورک استیشن مدل آذرخش Edge-Master 100

- SKU: AZ-WKS-EM100
- مشخصات:
- Processor: Threadripper PRO 7995WX (96 Cores)

- **GPU:** 2x NVIDIA RTX 6000 Ada Generation (96GB VRAM total)

- **Memory:** 256GB DDR5

- **قیمت:** ۶۸۰,۰۰۰,۰۰۰ تومان

۲.۲. ورک استیشن مدل آذرخش Nano-Agent (اقتصادی)

- **SKU:** AZ-WKS-NA10

- **مشخصات:**

- **Processor:** Intel Core i9-14900K

- **GPU:** 1x NVIDIA RTX 4090 (24GB VRAM)

- **Memory:** 128GB DDR5

- **قیمت:** ۲۱۰,۰۰۰,۰۰۰ تومان

۳. جدول مقایسه‌ای توان مصرفی و سیستم سرمایشی مورد نیاز

این بخش برای تست استخراج داده‌های مرتبط با زیرساخت در RAG بسیار حیاتی است.

حداقل فضای رک (Unit) خروجی حرارتی (BTU/h) توان مصرفی حداکثری (Watts) مدل دستگاه

Titan-X9	6500W	22,000	4U
Helios-G4	1200W	4,100	2U
Edge-Master	850W	2,900	Tower/5U
Nano-Agent	600W	2,050	Tower

۴. لیست قطعات جانبی و ارتقا (Spare Parts)

در صورتی که نیاز به ارتقای سیستم‌های موجود باشد، نرخ قطعات به شرح زیر است:

1. ماژول رم ۱۲۸ گیگابایت DDR5 ECC:

• کد: MEM-D5-128G-AZ

• قیمت: ۳۲,۰۰۰,۰۰۰ تومان

2. درایو NVMe ظرفیت ۷.۶۸ ترابایت:

• کد: STG-NV-768-ENT

• قیمت: ۵۸,۰۰۰,۰۰۰ تومان

3. کارت شبکه Dual Port 100GbE:

• کد: NET-NIC-100D

• قیمت: ۴۵,۰۰۰,۰۰۰ تومان

۵. سیاست‌های فروش و تخفیف حجیم (Volume Licensing)

شرکت آذرخش برای پروژه‌های ملی و دانشگاهی تخفیف‌های پله‌ای زیر را در نظر گرفته است:

- خرید بین ۵ تا ۱۰ دستگاه: ۴٪ تخفیف روی کل فاکتور.
- خرید بین ۱۱ تا ۲۵ دستگاه: ۷٪ تخفیف + نصب و راه‌اندازی رایگان در محل.
- خرید بیش از ۲۵ دستگاه: ۱۰٪ تخفیف + ۲ سال گارانتی تعویض طلایی آنی.

۶. زیرساخت‌های ذخیره‌سازی داده‌های حجیم (Storage Solutions - Series S)

در پروژه‌های RAG، سرعت فراخوانی بردارهای داده از دیتابیس‌های ولتی (Vector DB) به سرعت خواندن/نوشتن زیرساخت ذخیره‌سازی وابسته است.

۶.۱. سیستم ذخیره‌سازی تمام فلش (All-Flash Array) مدل Thunder-S1

• SKU: AZ-STG-TH1-AF

• معماری (NVMe-oF) NVMe-over-Fabrics :

• مشخصات فنی:

- **Controller:** Dual-Active Hot-swappable

- **Cache:** 128GB per controller

- **Max Throughput:** 25GB/s

- **IOPS:** 2,500,000 (Random Read)

- **جدول ظرفیت و قیمت (واحد: میلیون تومان):**

قیمت نهایی (تومان) تعداد درایو ظرفیت کل (Raw) مدل درایو انتخابی			
S1-P1 (Performance)	30.72 TB	4x 7.68TB	۱,۲۰۰,۰۰۰,۰۰۰
S1-C1 (Capacity)	61.44 TB	4x 15.36TB	۲,۱۰۰,۰۰۰,۰۰۰
S1-X1 (Extreme)	122.88 TB	8x 15.36TB	۳,۹۵۰,۰۰۰,۰۰۰

۷. تجهیزات شبکه مخصوص خوشه‌های هوش مصنوعی (AI Fabric Networking)

برای اتصال چندین سرور Titan-X9 به یکدیگر، استفاده از تجهیزات استاندارد پاسخگو نیست.

۷.۱. سوئیچ اینفینی‌بند مدل آذرخش Quantum-Link 800

- **SKU:** AZ-NET-QL800

- **کاربرد:** کاهش Latency در زمان اجرای Distributed Training توزیع وزن‌های مدل بین کارت‌های گرافیک مختلف.

- **تعداد پورت 32:** پورت 800Gb/s NDR

- **سیستم‌عامل:** Azarakhsh Network OS (ANOS)

- **قیمت واحد:** ۲,۴۵۰,۰۰۰,۰۰۰ تومان

۷.۲. کابل‌ها و فرستنده‌های نوری (Transceivers)

مدل	قیمت (تومان)	سرعت انتقال	متر/نوع
AZ-DAC-1M	۱۲,۵۰۰,۰۰۰	400Gbps	1 Meter DAC
AZ-AOC-5M	۳۸,۰۰۰,۰۰۰	400Gbps	5 Meter AOC
AZ-OPT-SR8 Multi-mode Optical	۸۵,۰۰۰,۰۰۰	800Gbps	

۸. لایسنس‌های نرم‌افزاری و پلتفرم‌های مدیریت (Software Licensing)

بخش نرم‌افزاری برای تست قابلیت‌های استخراج متن از لیست‌های غیرعددی بسیار مهم است.

۸.۱. پلتفرم مدیریت کلاستر "آذرخش نیولا" (Nebula OS)

این سیستم عامل لایه ارکستراسیون کانتینرها (Kubernetes) را برای پردازش‌های GPU مدیریت می‌کند.

- لایسنس Standard (تا ۵ گره): سالانه ۱۵۰,۰۰۰,۰۰۰ تومان
- لایسنس Professional (تا ۲۰ گره): سالانه ۴۵۰,۰۰۰,۰۰۰ تومان
- لایسنس Enterprise (نامحدود): سالانه ۱,۲۰۰,۰۰۰,۰۰۰ تومان

۸.۲. ماژول‌های تخصصی هوش مصنوعی

- ماژول بهینه‌ساز استنتاج (Inference Optimizer): کاهش حجم مدل‌ها با تکنیک‌های Quantization (INT8/FP8).
 - قیمت: ۹۵,۰۰۰,۰۰۰ تومان (دائمی)
- درایور اختصاصی پایداری بالا (High-Stability Drivers): جایگزین درایورهای استاندارد برای جلوگیری از کرش در لودهای ۱۰۰٪ طولانی مدت.
 - قیمت: ۴۰,۰۰۰,۰۰۰ تومان (به ازای هر سرور)

۹. جزئیات فنی پروتکل‌های پشتیبانی و نگهداری (SLA Details)

این بخش شامل پاراگراف‌های طولانی برای تست چانکینگ متنی است.

۹.۱. پروتکل رفع خطا در لایه سخت‌افزار (Hardware Failover)

در صورتی که یکی از کارت‌های گرافیک در سرورهای Titan-X9 دچار نقص فنی در سطح VRAM شود، سیستم مانیتورینگ آذرخش (Azarakhsh Insight) موظف است در کمتر از ۱۰۰ میلی‌ثانیه، پردازش را به گره رزرو منتقل کند. این فرآیند از طریق پروتکل اختصاصی AZ-Pulse مدیریت می‌شود. در صورتی که وقفه در پردازش بیش از ۵ ثانیه به طول انجامد، جریمه‌ای معادل ۰.۰۱٪ از کل مبلغ قرارداد به صورت روزانه از هزینه پشتیبانی کسر خواهد شد.

۹.۲. زمان‌بندی بازدیدهای دوره‌ای (Preventive Maintenance)

تیم فنی آذرخش موظف است هر ۳ ماه یک‌بار برای بررسی وضعیت خمیر سیلیکون پردازنده‌ها، گردگیری فن‌های با دور بالا (تا ۳۰۰۰۰ دور در دقیقه) و بررسی سلامت خازن‌های منبع تغذیه در محل سایت مشتری حاضر شود. گزارش این بازدیدها باید در سامانه مرکزی ثبت شده و به تایید مدیر فنی پروژه برسد.

۱۰. جدول نرخ دستمزد خدمات تخصصی (Professional Services)

این بخش برای کوئری‌های محاسباتی توسط Agent عالی است.

ضریب سختی (در صورت فوریت) نرخ پایه (تومان) واحد زمانی عنوان خدمت

۱.۵	۲۰,۰۰۰,۰۰۰	هر Node نصب و راه‌اندازی کلاستر
۱.۲	۵,۰۰۰,۰۰۰	هر ساعت آموزش پرسنل (Workshop)
۲.۰	۱۵,۰۰۰,۰۰۰	هر ترابایت بازگردانی داده (Data Recovery)
۱.۸	۱۲۰,۰۰۰,۰۰۰	هر مدل بهینه‌سازی مدل‌های LLM

۱۱. ضوابط و استانداردهای محیطی اتاق سرور (Environmental Requirements)

نصب تجهیزات سری Titan و Helios مستلزم رعایت دقیق استانداردهای زیر است. عدم رعایت این موارد موجب ابطال گارانتی می‌گردد.

۱۱.۱. سیستم کنترل دما و رطوبت (HVAC)

- **دمای عملیاتی:** دمای ورودی هوای سرد به جلو رک باید بین ۱۸ تا ۲۲ درجه سانتی‌گراد تثبیت شود.
- **رطوبت نسبی:** میزان رطوبت باید بین ۴۰٪ تا ۵۵٪ (Non-condensing) باشد.
- **سنسورهای پایش:** نصب حداقل ۲ سنسور دما در هر یونیت (بالا و پایین رک) الزامی است.

۱۱.۲. زیرساخت برق و ارتینگ (Earthing & Power)

- **ولتاژ ورودی:** ۲۲۰ ولت متناوب با نوسان حداکثر ۵٪.
- **چاه ارت:** مقاومت اهمی چاه ارت برای سرورهای محاسباتی سنگین باید کمتر از ۱ اهم باشد.
- **سیستم UPS:** استفاده از UPS با تکنولوژی Double Conversion و توان حداقل ۱.۵ برابر مصرف کل کلاستر الزامی است.

۱۲. پروتکل‌های عیب‌یابی و کدهای خطا (Error Codes & Troubleshooting)

این بخش برای تست **Semantic Search** سیستم [LUMIS.ai](https://lumis.ai) روی مفاهیم انتزاعی خطاها طراحی شده است.

۱۲.۱. کدهای خطای سطح سخت‌افزار (Hex-Codes)

در صورت بروز مشکل، نشانگرهای LED روی بدنه سرور کدهای زیر را نمایش می‌دهند:

1. **کد xEA10 (Thermal Throttling):** دمای پردازنده گرافیکی از ۹۵ درجه عبور کرده است.
 - **اقدام:** کاهش بار پردازشی به صورت خودکار و بررسی فن‌های شماره ۳ و ۴.
2. **کد xEB20 (ECC Memory Error):** بروز خطای تصحیح‌ناپذیر در ماژول رم.
 - **اقدام:** شناسایی اسلات معیوب از طریق بایوس و تعویض ماژول در کمتر از ۱۲ ساعت.
3. **کد xEC30 (Storage Latency):** تاخیر خواندن داده از NVMe بیش از ۲۰۰ میلی‌ثانیه است.
 - **اقدام:** بررسی سلامت کابل‌های OCuLink و بازنشانی کنترلر ذخیره‌سازی.

۱۲.۲. عیب‌یابی نرم‌افزاری پلتفرم نبولا (Nebula OS Debugging)

- مشکل:** عدم شناسایی کارت گرافیک در محیط کانتینر.
- راهکار:** اجرای دستور `az-check-gpu --verbose` و اطمینان از بارگذاری ماژول `nvidia-peermem`.
- مشکل:** کندی در جابه‌جایی چانک‌های داده در RAG.
- راهکار:** بررسی پهنای باند اینفینی‌بند با ابزار `ib_write_bw` و اطمینان از فعال بودن `GPUDirect RDMA`.

۱۳. لیست سیاه قطعات و محدودیت‌های سازگاری (Compatibility Blacklist)

برای جلوگیری از آسیب به برد اصلی، استفاده از قطعات زیر در سرورهای آذرخش ممنوع است:

نوع قطعه	برند/مدل غیرمجاز	علت محدودیت
ماژول رم	تمام برندهای Non-ECC	پایداری پایین در محاسبات طولانی
ذخیره‌سازی	SSDهای رده مصرف‌کننده (Samsung Evo)	عمر کوتاه (Low TBW) در لودهای سنگین
کارت شبکه	کابل‌های DAC بدون شیلد	تداخل الکترومغناطیسی با GPUها
منبع تغذیه	پاورهای تک‌ریله زیر ۱۵۰۰ وات	عدم توانایی در تامین Peak جریان برای H100

۱۴. سناریوهای استقرار (Deployment Scenarios)

در این بخش، سه سناریوی استاندارد برای فروش به مشتریان ارائه شده است.

سناریوی الف: آزمایشگاه هوش مصنوعی دانشگاهی (Academic Lab)

- هدف:** آموزش دانشجویان و اجرای مدل‌های سبک (تا ۷ میلیارد پارامتر).

- **پکیج پیشنهادی:** ۲ عدد ورک استیشن + Nano-Agent ۱ عدد سوئیچ ۱۰ گیگابیت.
- **هزینه تقریبی:** ۴۵۰,۰۰۰,۰۰۰ تومان.

سناریوی ب: مرکز پردازش داده‌های دولتی (Gov Data Center)

- **هدف:** پردازش اسناد طبقه‌بندی شده با امنیت بالا.
- **پکیج پیشنهادی:** ۳ عدد سرور Helios-G4 + سیستم ذخیره‌سازی Thunder-S1 + لایسنس اینترپرایز نبولا.
- **هزینه تقریبی:** ۷,۰۰۰,۰۰۰,۰۰۰ تومان.

سناریوی ج: کلاستر پردازش ابری (Cloud Provider)

- **هدف:** ارائه سرویس GPU-as-a-Service.
- **پکیج پیشنهادی:** ۱۰ عدد سرور Titan-X9 + شبکه ۸۰۰ گیگابیت + پشتیبانی طلایی ۵ ساله.
- **هزینه تقریبی:** ۱۸۰,۰۰۰,۰۰۰,۰۰۰ تومان.

۱۵. پیوست الف: واژه‌نامه فنی (Technical Glossary)

برای اینکه سیستم تو بتواند کلمات مخفف را به درستی متوجه شود:

- **RRF (Reciprocal Rank Fusion):** الگوریتم ترکیب نتایج جستجوی متنی و برداری.
- **Quantization:** فرآیند تبدیل وزن‌های مدل از FP32 به فرمت‌های سبک‌تر مثل INT4.
- **Cold Storage:** لایه‌ای از ذخیره‌سازی برای داده‌هایی که به ندرت فراخوانی می‌شوند (SATA HDD).
- **Hot Storage:** لایه ذخیره‌سازی بسیار سریع برای دیتابیس‌های عملیاتی (NVMe Gen5).